零基础读懂 Self-Attention

从“词互相看一眼”到 Query–Key–Value 公式

2026 年 4 月 22 日

基于 Lena Voita 的 NLP Course 中 Self-Attention: the “Look at Each Other” Part 小节整理。本文是中文零基础讲义，不是逐句翻译。

目录

1 这一节到底在解决什么 2

2 新的讲解原则 2

3 新手最该问的 5 个问题 3

4 Q1：Self-Attention 和普通 Attention 差在哪里 3

5 Q2：Token “看其它 token”是怎么计算的 3

6 Q3：Query、Key、Value 为什么要分三种角色 4

7 Q4：公式每一项是什么意思 5

8 把一个最小例子走完 6

9 代码里每一步对应什么 7

10 这一节和真实模型还差什么 8

11 一页复盘 8

1 这一节到底在解决什么

背景问题

我们已经知道，机器不能直接处理“词”，它处理的是向量。一句话进入 Transformer 以后，会先变成一排 token 向量。现在的问题是：**每个 token 怎样吸收同一句话里其它 token 的信息？**

例如一句话是：

The animal did not cross the street because it was tired.

里面的 *it* 到底指谁？单看 *it* 自己几乎看不出来。它必须回头看 *animal*、*street*、*tired* 等词，再根据整句话的语境更新自己的表示。

朴素直觉

Self-attention 的核心直觉很短：**一句话里的每个 token 都看同一句话里的其它 token，收集上下文，再更新自己**。这里的“self”不是“只看自己”，而是“同一组表示内部互相看”。

Lena Voita 的原文把这部分叫作模型中 token “look at each other” 的部分。这句话很重要：它不是把整句话压成一个单独向量，而是让每个位置都得到一个新的、带上下文的向量。

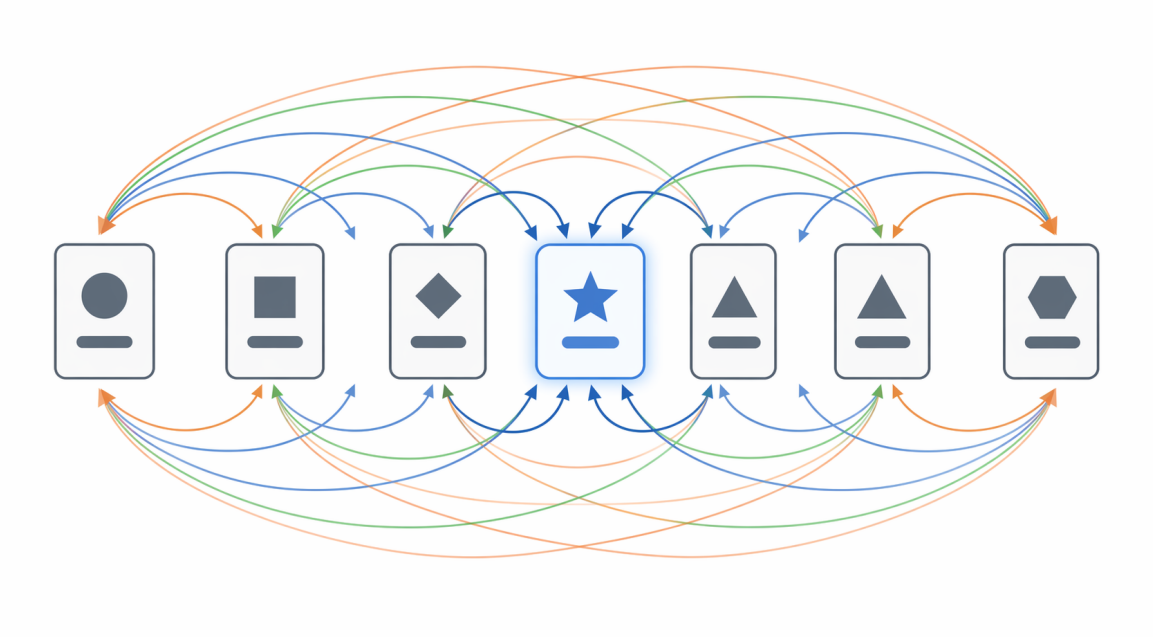

图 1: Self-attention 的视觉直觉：同一句话里的 token 并行地互相查看。图内没有写词，是为了把注意力放在“连接关系”本身。

2 新的讲解原则

本讲义按四层来解释，每层都只推进一个问题：

1. **背景问题**：为什么需要 self-attention?
2. **朴素直觉**：token 之间怎样“互相看”?

3. **数学表达**：Query、Key、Value 和公式每一项是什么意思？
4. **代码对应**：真实代码里通常会出现哪些张量形状？

这一页该记住

如果你第一次学 attention，不要先背公式。先记住：**谁在问**、**问谁**、**拿回什么信息**。公式只是把这三件事写成矩阵乘法。

3 新手最该问的 5 个问题

Q1. Self-attention 和普通 attention 的差别是什么？

Q2. “每个 token 看其它 token” 到底是怎么计算出来的？

Q3. Query、Key、Value 为什么要分成三种角色？

Q4. 公式 $\mathrm{softmax}(QK^\top/\sqrt{d_k})V$ 每一项在做什么？

Q5. 这和真实 Transformer 还差哪些部件？

4 Q1：Self-Attention 和普通 Attention 差在哪里

新手提问

普通 attention 也是“看别处”，self-attention 也是“看别处”。那为什么要多一个“self”？

定义

Attention 是一种“按相关程度汇总信息”的机制。如果被看的对象来自另一组表示，例如 decoder 当前状态去看 encoder 输出，这通常叫 encoder–decoder attention。

Self-attention 是同一组表示内部做 attention。例如 encoder 某一层里的所有 token 状态彼此查看，或者 decoder 某一层里已经允许查看的位置彼此查看。

更直白地说：

机制	直觉
普通 attention	我这一组表示，去看另一组表示。
self-attention	我们这一组表示，在组内互相看。

在 Transformer encoder 里，输入句子的所有 token 同时进入一层。这一层里的每个 token 都有机会看所有 token，包括自己。看完以后，每个 token 的向量都会变成“带上下文的新向量”。

5 Q2：Token “看其它 token” 是怎么计算的

新手提问

“看一眼” 听起来像比喻。模型真正能做的只有加减乘除。这个“看” 到底对应什么计算？

朴素直觉

先想一个极简版本。每个 token 都拿自己的向量去和其它 token 的向量做相似度比较。越相似，说明越应该多看一点；越不相关，就少看一点。最后把所有 token 的信息按权重加起来。

这一过程可以拆成三步：

1. **打分**：当前 token 和每个候选 token 算一个相关分数。
2. **归一化**：用 softmax 把分数变成一排权重，权重全为正且加起来等于 1。
3. **汇总**：用这些权重对候选 token 的信息做加权求和。

极简版公式

设第 i 个 token 的旧向量是 $\boldsymbol{x}_i$，第 j 个 token 的旧向量是 $\boldsymbol{x}_j$。如果暂时不区分 Query、Key、Value，可以写成：

$$s_{ij} = \boldsymbol{x}_i \cdot \boldsymbol{x}_j, \qquad a_{ij} = \frac{\exp(s_{ij})}{\sum_{r=1}^{n} \exp(s_{ir})}, \qquad \boldsymbol{z}_i = \sum_{j=1}^{n} a_{ij} \boldsymbol{x}_j.$$

这里 s_{ij} 是“第 i 个 token 对第 j 个 token 的相关分数”，a_{ij} 是归一化后的注意力权重，$\boldsymbol{z}_i$ 是第 i 个 token 汇总上下文后的新向量。

这一版能帮助理解，但它还不是 Transformer 的真实版本。真实版本不会直接用原始 $\boldsymbol{x}$ 去同时做所有事，而是把每个 token 映射成 Query、Key、Value 三个角色。

6 Q3：Query、Key、Value 为什么要分三种角色

新手提问

每个 token 已经有一个向量了。为什么还要制造 Query、Key、Value 三份？

朴素直觉

同一个人参加会议时可以有三种身份：

- 作为提问者，他带着一个问题；
- 作为被检索对象，他要展示一个“索引标签”；
- 作为信息提供者，他真正贡献一段内容。

Self-attention 把一个 token 向量拆成这三种身份。

三者的分工如下：

角色	人话解释
Query Q	“我现在想找什么信息？”它属于正在更新自己的 token。
Key K	“我这里有什么信息可供匹配？”它属于被查看的候选 token。
Value V	“如果你决定看我，我实际给你什么内容？”它是最终被加权汇总的信息。

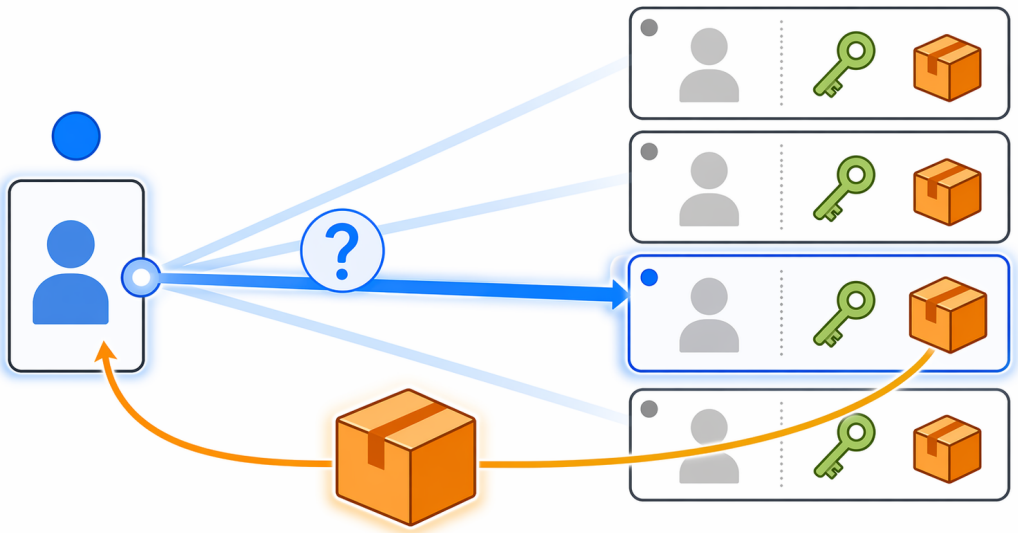

图 2: Query、Key、Value 的角色隐喻：左边 token 发出查询；右侧 token 用 key 参与匹配；匹配强的位置把 value 信息贡献回来。

这正对应原网页的小节：query 用来询问信息，key 用来响应并计算权重，value 用来贡献最终输出。

7 Q4：公式每一项是什么意思

新手提问

很多教材直接写：

$$\mathrm{Attention}(Q,K,V)=\mathrm{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right)V.$$

这串符号到底在说什么？

先从单个 token 说起。假设第 i 个 token 的输入向量是 $\boldsymbol{x}_i$。模型会用三个可训练矩阵把它变成三种角色：

从一个 token 到三种角色

$$\boldsymbol{q}_i=\boldsymbol{x}_iW_Q,\qquad \boldsymbol{k}_i=\boldsymbol{x}_iW_K,\qquad \boldsymbol{v}_i=\boldsymbol{x}_iW_V.$$

这里 $\boldsymbol{q}_i$ 是第 i 个 token 的 query 向量，$\boldsymbol{k}_i$ 是它的 key 向量，$\boldsymbol{v}_i$ 是它的 value 向量。W_Q,W_K,W_V 是训练学出来的矩阵。

接着，第 i 个 token 要决定看第 j 个 token 多少，就比较：

$$\boldsymbol{q}_i \cdot \boldsymbol{k}_j.$$

这句话的人话版本是：**第 i 个 token 的问题，和第 j 个 token 展示出来的索引标签，有多匹配？**

缩放点积注意力

$$\alpha_{ij} = \mathrm{softmax}_j\left(\frac{\boldsymbol{q}_i \cdot \boldsymbol{k}_j}{\sqrt{d_k}}\right), \qquad \boldsymbol{z}_i = \sum_{j=1}^{n} \alpha_{ij}\boldsymbol{v}_j.$$

α_{ij} 是第 i 个 token 分给第 j 个 token 的注意力权重。d_k 是 key/query 向量的维度。$\boldsymbol{z}_i$ 是第 i 个 token 更新后的上下文向量。

把所有 token 一次性堆成矩阵，就得到常见公式：

矩阵形式

$$Q = XW_Q, \qquad K = XW_K, \qquad V = XW_V,$$

$$\boxed{\mathrm{Attention}(Q, K, V) = \mathrm{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right) V}.$$

其中 X 是一整句话的输入矩阵；$QK^\top$ 是所有 token 两两之间的匹配分数表；$\mathrm{softmax}(\cdot)$ 把每一行分数变成权重；最后乘 V，就是把 value 信息按权重汇总。

为什么要除以 $\sqrt{d_k}$

朴素直觉

点积是很多项相加。向量维度 d_k 越大，点积数值越容易变大。如果分数太大，softmax 会变得非常尖锐：最大的那个位置几乎拿走全部权重。除以 $\sqrt{d_k}$ 是为了把分数压回温和范围，让模型保持“软选择”。

8 把一个最小例子走完

假设一句话有 4 个 token，每个 token 的隐藏维度是 3：

$$X \in \mathbb{R}^{4\times 3}.$$

再假设这一层把 query/key/value 都投影到 2 维：

$$W_Q, W_K, W_V \in \mathbb{R}^{3\times 2}.$$

那么形状会这样变化：

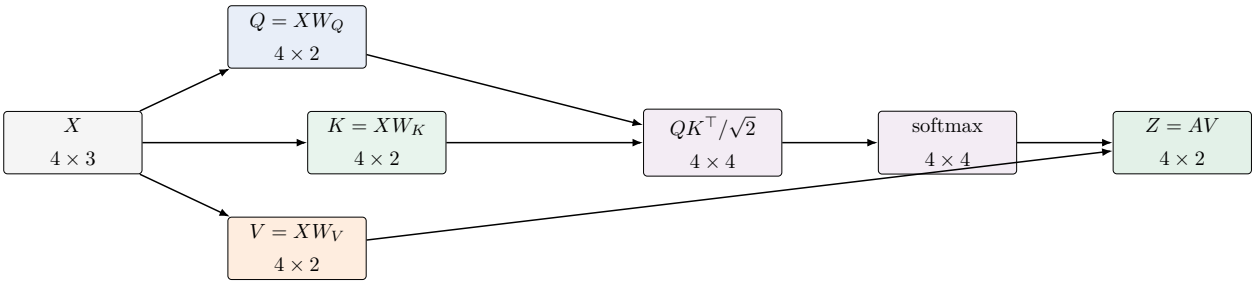

这一页该记住

4×4 的注意力权重矩阵 A 最容易误解。它不是输出本身，而是一张“谁看谁多少”的表。真正的新 token 表示是 $Z = AV$。

9 代码里每一步对应什么

下面是一段简化 PyTorch 代码。它不追求完整工程结构，只帮助你把公式对回代码。

代码对应

```python
import torch
import torch.nn as nn

class SelfAttention(nn.Module):
    def __init__(self, d_in, d_k):
        super().__init__()
        self.W_q = nn.Linear(d_in, d_k, bias=False)
        self.W_k = nn.Linear(d_in, d_k, bias=False)
        self.W_v = nn.Linear(d_in, d_k, bias=False)

    def forward(self, x):
        # x: (batch, seq_len, d_in)
        Q = self.W_q(x) # (batch, seq_len, d_k)
        K = self.W_k(x) # (batch, seq_len, d_k)
        V = self.W_v(x) # (batch, seq_len, d_k)

        scores = Q @ K.transpose(-2, -1) # (batch, seq_len, seq_len)
        scores = scores / (K.shape[-1] ** 0.5)
        weights = torch.softmax(scores, dim=-1)

        out = weights @ V # (batch, seq_len, d_k)
        return out, weights
```

逐行对照：

1. `W_q/W_k/W_v` 对应 W_Q, W_K, W_V，是模型要学习的参数。
2. `scores` 对应 $QK^\top$，表示每个 token 对每个 token 的匹配分数。

3. `softmax(scores, dim=-1)` 表示每一行单独归一化：每个查询 token 都有自己的一排注意力权重。
4. `weights @ V` 对应最后的加权汇总。

10 这一节和真实模型还差什么

到这里，我们只解释了 self-attention 的核心。真实 Transformer 还会继续加几层东西：

1. **Masked self-attention**：decoder 生成文本时不能偷看未来 token，所以会把未来位置遮住。
2. **Multi-head attention**：不是只用一套 Q/K/V，而是分成多个头，让不同头关注不同关系。
3. **残差连接和 LayerNorm**：帮助深层网络稳定训练。
4. **前馈网络**：attention 负责混合 token 之间的信息，前馈网络负责进一步变换每个位置的表示。

这一页该记住

本节目标不是把 Transformer 全部讲完。本节只要拿下一个核心句子：**self-attention 让同一句话内部的 token 用 Q/K 匹配权重，再用这些权重汇总 V，从而更新每个 token 自己**。

11 一页复盘

关键词	应该记住的人话版本
Self-attention	同一组 token 表示内部互相看。
Query	当前 token 想找什么。
Key	候选 token 怎样被匹配到。
Value	候选 token 真正贡献的信息。
$QK^\top$	所有 token 两两之间的匹配分数表。
softmax	把分数变成一排“加起来等于 1”的权重。
$\mathrm{softmax}(QK^\top/\sqrt{d_k})V$	先决定看谁多少，再按权重把 value 汇总回来。

这一页该记住

不要把 attention 想成一个神秘模块。它就是三步：**算相关分数，变成权重，加权汇总信息**。Query、Key、Value 只是让这三步变得可学习、可训练。